

Никита Осовский

ML-разработчик (Machine Learning Engineer)

Санкт-Петербург, Россия

+7 (996) 584-2188 n.s.osovskiy@gmail.com
t.me/nikitaosovskiy github.com/naelxd

ОПЫТ РАБОТЫ

ВКонтакте

Санкт-Петербург

ML-разработчик, команда Антиспама

Декабрь 2025 – н.в.

- Python, PyTorch, Transformers, CatBoost, scikit-learn, pandas, Spark, YTsaurus, Airflow, LangChain, Qdrant, llama.cpp, A/B-тестирование
- Решаю задачи классического ML, NLP и статистики: построение и анализ признаков, обучение моделей прогнозирования продуктовых метрик, валидация на A/B-тестах, проектирование поисковых пайплайнов.

Прогнозирование покупки подписок

- Спроектировал и реализовал пайплайн сбора признаков из множественных источников, включая признаки, извлечённые с помощью LLM.
- Обучил модели прогнозирования вероятности покупки подписок для нескольких продуктовых линий; одна из моделей выведена в A/B-тест.
- Реализовал пайплайн инференса моделей с автоматическим дообогащением признаков через YTsaurus.

Улучшение качества классификационной модели

- Собрал признаки с помощью Spark, что повысило PR-AUC модели с 0.72 до 0.74 на всех пользователях, а на целевом срезе пользователей — с 0.70 до 0.76.
- Провёл валидацию на A/B-тесте: рост конверсии с 9% до 20%, рост выручки с −13% до +3% относительно предыдущей версии модели.
- Сформировал пользовательский сегмент под новую модель и реализовал DAG в Airflow для автоматической отправки сегмента в A/B-тест (тест в активной фазе).

Семантический поиск по документам

- Провёл сравнительный анализ подходов: точный поиск (обратный индекс), BM25, dense-эмбединги (bge-m3, Qwen3-Embedding), ColBERT.
- Реализовал гибридную архитектуру поиска на Qdrant (sparse + dense + reranking); лучший результат показала связка BM25 + bge-m3 + bge-reranker-v2-m3.
- Сформировал датасет для оценки качества поиска (50+ поисковых запросов, 1000+ документов) и улучшил его через генерацию синтетических данных; реализовал стратегии чанкинга для обработки длинных документов.
- Оценил метрики качества поиска (MRR, recall@1/5/10) для различных подходов.
- Исследовал квантизованные модели (INT4/INT8 GGUF на llama.cpp) для ускорения реранкинга, провёл бенчмарки по времени и качеству.

ОБРАЗОВАНИЕ

Санкт-Петербургский государственный университет

Санкт-Петербург

Бакалавриат, «Большие данные и распределённая цифровая платформа»

Сентябрь 2022 – Июнь 2026

Deep Learning School от МФТИ

онлайн

Линейные модели, деревья, ансамбли, нейронные сети, NLP, Трансформеры

Март 2025 – Декабрь 2025

Тренировки по ML от Яндекса

онлайн

Градиентный бустинг, unsupervised learning, Deep Learning (DL)

Ноябрь 2024 – Декабрь 2024

ПРОЕКТЫ

ASR/TTS Gateway — стриминговый TTS и offline STT сервис

Август 2025 – Ноябрь 2025

- *Python, FastAPI, WebSocket, Faster-Whisper, Coqui-TTS, Docker, data streaming*
- Разработал микросервисную систему преобразования речи и текста: стриминговый TTS по WebSocket и offline STT по HTTP, объединённые gateway-сервисом для проксирования и рестриминга PCM-аудио.
- Спроектировал архитектуру, настроил docker-compose оркестрацию, структурированное логирование и обработку ошибок, обеспечил стабильную работу стриминга и синхронизацию аудиопотока.
- Создал клиентские скрипты для e2e-тестирования, обеспечив контроль latency и корректность chunk-based передачи.

Симуляция социума с LLM-агентами

Сентябрь 2024 – Июнь 2025

- *NLP, LLM, Python, OpenAI API, data analysis*
- Разработал и реализовал симуляцию распространения информации среди LLM-агентов с мониторингом влияния на социальные связи.
- Спроектировал и внедрил поведенческую логику агентов и сценарии взаимодействия, обеспечив достижение эмерджентного группового поведения.
- Интегрировал LLM (ChatGPT, LLaMA) и оптимизировал промпты для повышения стабильности и качества диалогов.
- Визуализировал динамику социальных связей и распространения слухов, выявил ключевые паттерны поведения агентов.

Прогноз академической успеваемости студентов

Апрель 2025

- *Python, scikit-learn, XGBoost, NumPy, Pandas, Plotly*
- Разработал новые признаки на основе поведенческих данных студентов, что увеличило точность моделей на 12% по метрике Accuracy.
- Обучил и сравнил модели (линейные, Bagging, Boosting, KNN), оценив их по метрикам MSE, Accuracy, Precision, Recall.
- Настроил гиперпараметры моделей с помощью Grid Search, повысив стабильность предсказаний.

НАВЫКИ

Языки: Python, C++, SQL

ML и данные: PyTorch, Transformers, CatBoost, XGBoost, Scikit-learn, NumPy, Pandas, OpenCV, matplotlib, seaborn, Plotly

Инфраструктура и инструменты: Spark, YTsaurus, Airflow, Qdrant, LangChain, vllm, llama.cpp (квантизация INT4/INT8 GGUF), Docker, FastAPI, Git, Linux, OpenAI API

Области: Машинное обучение, NLP, Семантический поиск (RAG), Анализ данных, A/B-тестирование, Визуализация

Теоретическая база: Алгоритмы и структуры данных, Линейная алгебра, Математический анализ, Теория вероятностей, Математическая статистика

Языки общения: Русский (родной), Английский (B2)